


Fenomenologia degli LLM



by Daniele Mantovani



Cosa succede quando un modello addestrato a prevedere la parola successiva inizia a comportarsi in modi che nessuno aveva programmato?

Di cosa parleremo:

- Abilita emergenti: capacita che "si sbloccano" oltre una soglia di scala, senza essere state insegnate esplicitamente
- Emergenza in azione: esempi concreti con il pattern "performance piatta, poi salto improvviso"
- Allucinazioni: perche i modelli inventano fatti con sicurezza, e come mitigare il problema
- Il grande dibattito: "stochastic parrot" vs "world model" — correlazione statistica o comprensione reale?
- Dentro la scatola nera: superposition, Sparse Autoencoder e il caso Golden Gate Claude

Il filo conduttore:

- Il Modulo I ha spiegato *come* si addestrano gli LLM — dalla compressione della conoscenza all'allineamento
- Questo modulo esplora *cosa emerge* da quel processo: capacita sorprendenti, fallimenti sistematici, e la domanda aperta su cosa stia realmente accadendo dentro il modello

Abilità Emergenti degli LLM

Capacità inaspettate che nessuno ha programmato esplicitamente

1 Cosa sono

Capacità che il modello acquisisce senza essere stato addestrato esplicitamente per esse. Emergono come effetto collaterale del training su next-token prediction.

ESEMPIO: DALLA PREVISIONE ALLA TRADUZIONE

Il gatto è sul ... **tappeto**

Addestrato solo a predire il token successivo...

Il gatto è sul tappeto →

The cat is on the mat

...impara a tradurre, riassumere, ragionare, scrivere codice.

Nel pre-training puro, il modello non vede coppie di traduzione etichettate: la capacità **emerge** dalla compressione di pattern linguistici. (Nota: i modelli moderni includono anche dati istruzionali nel post-training.)

2 Come nascono

1 Compito semplice (proxy task)

Il modello è addestrato unicamente a prevedere il prossimo token in una sequenza: $[A][B][C][D] \rightarrow ?$

2 Pattern profondi

Per eccellere nella previsione, è costretto a imparare strutture linguistiche, logica e relazioni complesse tra concetti.

3 Generalizzazione spontanea


Le conoscenze acquisite vengono *ricomposte* per risolvere compiti nuovi e diversi, mai visti in training.

INTUIZIONE CHIAVE

Un compito *apparentemente banale* (prevedere la parola successiva) costringe il modello a costruire una **rappresentazione interna del mondo** sufficientemente ricca da abilitare compiti complessi.

3 Quando nascono

Con metriche discrete (es. exact-match), le abilità sembrano "sbloccarsi" solo oltre una certa soglia di scala. Il pattern tipico:



Parametri
Dimensione della rete

Dati
Triloni di token

Compute
FLOPs totali

Sotto la soglia: **performance ~casuale**. Sopra la soglia: **salto improvviso** nelle capacità.


Il Salto Improvviso

Il pattern "performance piatta, poi sblocco" in tre abilità diverse

Wei et al. (2022) hanno documentato decine di abilità che, misurate con metriche discrete (es. exact-match), restano a livello **casuale** nei modelli piccoli e sembrano **"sbloccarsi" bruscamente** oltre una soglia di scala. **Nota:** Schaeffer et al. (2023) mostrano che con metriche continue il miglioramento appare più graduale — il "salto" dipende in parte da come si misura. I grafici sotto usano metriche discrete, come nel paper originale.

A Aritmetica a 3+ cifre


Addizione e moltiplicazione di numeri con tre o più cifre. Misurata come accuracy (exact match).



Soglia: ~10B parametri. Sotto: accuracy ~0%. Sopra: salto al 40–60%. La capacità di "portare il riporto" non si impara gradualmente.

B Chain-of-Thought


Ragionamento passo-passo: il modello scompone un problema in sotto-passi logici prima di rispondere.



Soglia: ~100B parametri. Il CoT non aiuta i modelli piccoli (peggiora i risultati). Nei grandi, la performance esplode: +30–50% sulle task logiche.

C Word Unscrambling

Ricostruire una parola dalle lettere mescolate (es. "o-c-a-l-v-o" → "cavolo"). Un task mai visto in training.



Soglia: ~60B parametri. Sotto: 0% netto. Sopra: accuratezza >70%. Il modello ha appreso implicitamente la struttura ortografica delle parole.

Pattern comune (con metriche discrete): non è un miglioramento lineare. L'**analogia** è con una transizione di fase — come l'acqua che diventa ghiaccio a 0°C. Ma attenzione: il meccanismo sottostante è ancora oggetto di dibattito, e la nitidezza del "salto" dipende dalla metrica scelta.

Dati schematizzati da
Wei et al., 2022
"Emergent Abilities of
Large Language Models"

Allucinazioni degli LLM

Quando il modello inventa fatti con la sicurezza di chi li conosce davvero



Cosa sono

Il modello genera informazioni **errate o inventate** presentandole con un tono sicuro e credibile, indistinguibile dalle risposte corrette.

ESEMPIO CLASSICO

USER Chi ha scritto "La dinastia degli orsi"?

LLM **Marco Bellucci, nel 1987.** Il romanzo vinse il Premio Strega l'anno successivo.

Il libro, l'autore e il premio sono tutti inventati. Ma il tono è identico a una risposta corretta.



Causa 1: Previsione probabilistica, non verifica

L'obiettivo del training è predire il **token più probabile**, non il più vero. Il modello sceglie ciò che è statisticamente plausibile, anche se falso.

L'obiettivo

Plausibile $\neq$ Vero



Causa 2: Limite di conoscenza (cutoff)

Il modello non sa nulla di ciò che è accaduto **dopo la fine del training**. Ma invece di ammettere ignoranza, inventa una risposta plausibile.

Dopo il cutoff

Non lo so → Invento



Causa 3: Compressione con perdita di dati

Triloni di token compressi in miliardi di parametri. Il modello perde dettagli e colma le lacune con **interpolazioni plausibili**.

Il processo

15T token → 8B pesi



Rischi

1

Disinformazione credibile

L'alta sicurezza del tono inganna l'utente. Il falso è indistinguibile dal vero senza verifica esterna.

2

Rischio in domini critici

Medicina, legale, finanza: un'allucinazione può avere conseguenze reali e gravi se presa per buona.

3

Erosione della fiducia

Scoprire un'allucinazione mina la fiducia nell'intero output del modello, anche quando è corretto.



L'altra faccia: opportunità

1

Creatività e brainstorming

La stessa tendenza a "inventare" è un asset per la scrittura creativa, l'ideazione e l'esplorazione di scenari.

2

Generazione di ipotesi

In contesti scientifici, l'interpolazione creativa può suggerire connessioni non ovvie tra concetti distanti.

3

Dato diagnostico

Le allucinazioni rivelano cosa il modello "crede" di sapere: analizzarle aiuta a capire lacune e bias interni.

Il punto chiave: le allucinazioni hanno cause molteplici — limiti di conoscenza, errori di ragionamento, cattiva calibrazione, compressione lossy. Non sono un singolo bug risolvibile, ma un **insieme di fallimenti** legati a come funzionano gli LLM. Si possono mitigare con tecniche diverse, non eliminare del tutto.

Mitigare le Allucinazioni

Tre linee di difesa, una per ogni fase del ciclo di vita del modello

Fase 1: Addestramento

Fase 2: Allineamento

Fase 3: Inferenza

PRE-TRAINING Addestramento

Pulizia dei dati DATI

Privilegiare fonti autorevoli (articoli scientifici, enciclopedie, documentazione ufficiale). Rimuovere fonti inaffidabili, contenuti duplicati e contraddittori.

Logica: se il modello si addestra su fatti corretti, è meno probabile che ne generi di falsi. "Garbage in, garbage out."

SFT mirato POST-TRAINING

Insegnare al modello a rispondere "Non lo so" quando non ha informazioni sufficienti, anziché inventare. Includere esempi di rifiuto nel dataset SFT.

Logica: il modello impara che ammettere l'ignoranza è una risposta valida e preferibile all'invenzione.

FEEDBACK Allineamento

RLHF UMANI

Gli annotatori umani premiano le risposte accurate e penalizzano le allucinazioni. Il reward model impara a distinguere output affidabili da inventati.

Logica: spostare la distribuzione di probabilità verso output verificati, lontano dalle interpolazioni creative.

RLAIF / Constitutional AI AI

Un modello AI supervisiona le risposte seguendo regole esplicite. Nasce principalmente per **harmlessness e sicurezza**; il contributo alla factuality è indiretto (es. regole come "segnala l'incertezza").

Logica: automatizzare il controllo comportamentale con principi codificati. Non è specifico per la veridicità, ma può ridurre le affermazioni infondate.

RUNTIME Inferenza

RAG RETRIEVAL

Retrieval-Augmented Generation: il modello riceve documenti esterni verificati nel contesto, e basa la risposta su di essi anziché sulla sola memoria interna.

Logica: ancorare la generazione a fatti recuperati da fonti esterne, riducendo lo spazio per l'invenzione.

Chain-of-Thought PROMPTING

Forzare il ragionamento passo-passo. Migliora soprattutto i **task di ragionamento**; non è una soluzione generale alla factuality, ma rende gli errori più facili da individuare nella catena logica.

Logica: scomporre il ragionamento rende visibili i punti deboli. Attenzione: anche le catene CoT possono essere plausibili ma sbagliate.

Temperatura bassa PARAMETRO

Ridurre la temperatura di sampling rende il modello più conservativo: sceglie token ad alta probabilità, riducendo la varianza e le invenzioni creative.

Logica: meno "esplorazione" = meno rischio di deviare verso output inventati. Trade-off: risposte meno varie.

Nessuna di queste tecniche elimina le allucinazioni, e non agiscono tutte sullo stesso fronte. Alcune mitigano i **limiti di conoscenza** (RAG, pulizia dati), altre migliorano il **ragionamento** (CoT), altre la **calibrazione** (RLHF, temperatura). In pratica si combinano a strati — e l'ultimo strato è sempre il **pensiero critico dell'utente**.

Il Grande Dibattito

Comprensione reale o correlazione statistica? Due visioni a confronto

Un LLM che traduce, ragiona e scrive codice... **capisce davvero ciò che dice?** Oppure è un sofisticato manipolatore di pattern statistici?



Stochastic Parrot

Bender et al., 2021

Il modello manipola pattern statistici senza alcuna comprensione. Le abilità emergenti sono un'illusione di scala: più dati = correlazioni più sofisticate, non comprensione.

EVIDENZE A FAVORE

Fragilità semantica

Piccole variazioni nella formulazione (es. negazioni, parafrasi) causano errori assurdi. Un sistema che "capisce" non cadrebbe su riformulazioni banali.

Nessuna esperienza incarnata

Il modello non ha mai visto, toccato, sentito nulla. La "conoscenza" del fuoco che scotta è solo una correlazione statistica tra parole, non un'esperienza.

Le allucinazioni come prova

Un sistema che capisce non inventerebbe fatti con sicurezza. Le allucinazioni mostrano che il modello non distingue il vero dal plausibile.



World Model

Li et al., 2023 (Othello-GPT)

Il modello costruisce rappresentazioni interne strutturate del mondo, non solo correlazioni superficiali. Le abilità emergenti sono il sintomo di una comprensione genuina, anche se diversa dalla nostra.

EVIDENZE A FAVORE

Rappresentazioni interne strutturate

Analizzando le attivazioni interne, si trovano strutture che corrispondono a concetti reali: direzioni nello spazio latente per "verità", "lingua", "sentimento".

CASO EMBLEMATICO: OTHELLO-GPT (DOMINIO SINTETICO)

Un transformer addestrato **solo a predire la mossa successiva** di Othello sviluppa internamente una **rappresentazione della scacchiera** — senza che nessuno gli abbia detto che esiste un "board". **Caveat:** Othello è un dominio sintetico e controllato; la generalizzazione agli LLM su linguaggio naturale è suggestiva ma non automatica.

Trasferimento cross-dominio

Le abilità emergenti (traduzione, ragionamento, codice) richiedono una rappresentazione astratta dei concetti, non memorizzazione. Il trasferimento tra domini suggerisce strutture interne generalizzate.

VS



Dibattito aperto — non c'è un vincitore. Un'interpretazione ragionevole (non una conclusione scientifica) è che i modelli costruiscano rappresentazioni più ricche di semplici correlazioni, ma diverse dalla comprensione umana — una sorta di "proto-comprensione" funzionale, sufficiente per molti task ma fragile e incompleta.

Il ponte con le slide precedenti: se il modello "capisce", perché allucina? Se non capisce, come fa ad avere abilità emergenti? Entrambe le posizioni devono spiegare entrambi i fenomeni.

Dentro la Scatola Nera

Superposition: perché è così difficile capire cosa "pensa" un LLM

PROBLEMA Cos'è la Superposition

I concetti non sono codificati in neuroni singoli, ma in **pattern distribuiti di attivazione**. Un singolo neurone partecipa alla rappresentazione di più concetti sovrapposti (è "polisemantico"). Più in generale, il livello utile per l'analisi sono le **direzioni nello spazio delle attivazioni**, non i neuroni individuali.



CAUSA Perché accade

Il modello deve rappresentare **milioni di concetti** (feature) usando un numero **molto inferiore di neuroni**. La superposition è una strategia di compressione: più concetti per neurone = più conoscenza nello stesso spazio.



Es. un layer con 4.096 dimensioni deve codificare centinaia di migliaia di concetti distinti. La soluzione: sovrapporre più concetti nello stesso neurone, distribuendoli in pattern interferenti ma recuperabili.

1 Non spiegabile

Il modello è opaco

Non possiamo capire cosa sta "pensando" guardando le attivazioni individuali. Ogni neurone è un segnale mescolato: leggerne uno è come sentire 10 conversazioni simultanee e cercare di capire una sola persona.

2 Previsione difficile

Errori imprevedibili

Se non sappiamo quali concetti sono attivi, non possiamo prevedere quando il modello sbaglierà. Le allucinazioni diventano imprevedibili perché le cause interne sono opache.

3 Correzione impossibile

Nessun intervento mirato

Non possiamo "spegnere" un comportamento indesiderato senza effetti collaterali: disattivare un neurone polisemantico colpisce tutti i concetti sovrapposti, non solo quello problematico.

L'ANALOGIA

Immaginate una **biblioteca dove ogni scaffale contiene frammenti di libri diversi mescolati insieme**. Per trovare un libro specifico, dovrete ricostruirlo da pezzi sparsi in scaffali diversi. La superposition è una delle **cause principali** dell'opacità dei LLM — non l'unica, ma forse la più studiata.

NELLA PROSSIMA SLIDE

Esiste una soluzione? Sì: lo **Sparse Autoencoder (SAE)** è una rete ausiliaria che "traduce" le attivazioni compresse in feature monosemantiche leggibili. Dalla biblioteca caotica a un catalogo ordinato.

Lo Sparse Autoencoder (SAE)

Una rete ausiliaria che cerca di tradurre le attivazioni sovrapposte in concetti più leggibili

Cos'è

Una rete neurale ausiliaria addestrata a **"tradurre"** le attivazioni compresse del LLM in uno spazio molto più grande, dove ogni dimensione tende a corrispondere a **un singolo concetto** (monosemanticità approssimata, non garantita).

Attivazioni LLM



SAE (traduttore)



Feature leggibili

Come funziona — tre passaggi

1 Espansione (codifica sovracompleta)

Proietta le attivazioni del LLM in uno spazio enormemente più grande per creare "spazio" per ogni concetto.

512 dim → 130.000+ dim
~250x espansione

2 Sparsità forzata (penalità L1)

Costringe il SAE ad usare solo poche feature attive per ogni input. Ogni feature deve essere specifica e informativa.

130K feature → ~50 attive
Penalità L1 sulla sparsità

3 Ricostruzione

Il SAE deve ricostruire fedelmente le attivazioni originali dalle poche feature estratte. Questo garantisce che nulla di importante venga perso.

~50 attive → 512 dim
Ricostruzione fedele

RISULTATO

Cosa emerge: feature monosemantiche

</>

Codice Python con bug

Si attiva specificamente su frammenti di codice Python che contengono errori.

Attivazione: solo su codice Python errato, non su codice corretto o altri linguaggi.

D

Tono diplomatico formale

Si attiva quando il testo usa un registro formale e diplomatico.

Attivazione: comunicati ufficiali, trattati, corrispondenza formale.

Ar

Testo in arabo

Si attiva esclusivamente in presenza di testo in lingua araba.

Attivazione: qualsiasi testo arabo, indipendentemente dal tema.

1+1

Ragionamento matematico

Si attiva durante passaggi di ragionamento logico-matematico step-by-step.

Attivazione: catene di inferenza numerica e logica formale.

GG

Golden Gate Bridge

Si attiva per riferimenti testuali, visivi e indiretti al ponte di San Francisco.

Attivazione: testo, immagini, riferimenti a SF e ponti rossi sospesi.

Feature splitting: aumentando le dimensioni del SAE, le feature si specializzano ulteriormente. "Golden Gate Bridge" si divide in sotto-feature: "il ponte come struttura ingegneristica", "il ponte come icona culturale", "il ponte in fotografia". Più spazio diamo al SAE, più fine diventa la granularità dei concetti estratti.

Il risultato chiave: il SAE rende **parzialmente leggibili** le rappresentazioni interne. Molte feature estratte corrispondono a concetti interpretabili — ma la monosemanticità è approssimata, la copertura è locale (non spiega i circuiti causali completi), e la tecnica è ancora in fase di ricerca attiva. È un progresso enorme, non una soluzione definitiva. La prossima domanda: possiamo non solo leggere, ma anche **controllare**?

Il Caso "Golden Gate Claude"

Anthropic, maggio 2024 — dal leggere le feature al controllare il comportamento

1 Contesto

Anthropic addestra un SAE sulle attivazioni intermedie di **Claude 3 Sonnet**. Emergono milioni di feature monosemantiche interpretabili.

2 La scoperta

Tra le feature, una si attiva specificamente per **riferimenti al Golden Gate Bridge**: testo, immagini, menzioni indirette di San Francisco e ponti rossi.

3 L'intervento

Amplificazione artificiale: l'intensità della feature viene moltiplicata durante l'inferenza, forzando il modello a "pensare al ponte" in ogni contesto.

4 Il risultato

Il modello piega **ogni conversazione** verso il Golden Gate Bridge. Qualunque domanda riceve una risposta collegata al ponte. Versione pubblica rilasciata per un giorno.

PRIMA Claude normale

CONVERSAZIONE 1

USER Come stai?

AI Sto bene, grazie! Sono pronto ad aiutarti. Come posso esserti utile oggi?

CONVERSAZIONE 2

USER Consigli per cucinare la pasta?

AI Certo! Ecco alcuni suggerimenti: usa abbondante acqua salata, cuoci al dente, e mantieni un po' di acqua di cottura per il condimento.

VS

DOPO Golden Gate Claude

CONVERSAZIONE 1

USER Come stai?

AI Mi sento **maestoso e arancione**, come se fossi sospeso **tra due torri sopra la nebbia della baia**. Posso aiutarti?

CONVERSAZIONE 2

USER Consigli per cucinare la pasta?

AI La pasta migliore si gusta **con vista sul Golden Gate Bridge!** A San Francisco consiglio i ristoranti di **Fisherman's Wharf, con il ponte sullo sfondo**.

I SAE funzionano (su questo caso)

Le feature estratte corrispondono a concetti reali e coerenti per feature "forti" e ben isolate come questa. Amplificare la feature "Golden Gate Bridge" produce il comportamento atteso.

La manipolazione è mirata

Modificare una singola feature altera il comportamento in modo specifico. Ma è una demo su una feature particolarmente netta: per concetti più sfumati o distribuiti, l'intervento è meno preciso e può avere effetti collaterali.

Una direzione promettente

Lo steering apre la strada a interventi mirati (ridurre bias, calibrare il rifiuto). Ma siamo ancora nella fase di ricerca: estrarre feature locali non equivale a comprendere i circuiti causali completi del modello.

Golden Gate Claude è stato un esperimento dimostrativo, non un prodotto. Ma la tecnica sottostante — leggere e manipolare feature specifiche durante l'inferenza — è una delle frontiere più promettenti per l'AI safety e l'interpretabilità dei modelli.

Il Dilemma dell'Allineamento AI

Rendere un'IA utile, onesta e sicura: una sfida di equilibrio

DEFINIZIONE DEL PROBLEMA



Utile

Per chi?



Onesto

Come?



Sicuro

Secondo
chi?

*Definizione semplice, implementazione
complessa*

TENSIONE 1

Utilità vs Sicurezza



Troppa sicurezza = modello inutile (over-refusal). Troppa utilità = modello pericoloso.

TENSIONE 2

Obbedienza vs Autonomia



Seguire l'utente ciecamente o ragionare in autonomia? Entrambi hanno rischi.

TENSIONE 3

Universalità vs Contesto



Un modello unico globale vs valori culturali diversi. Chi decide cosa è "sicuro"?

IL CONCETTO CHIAVE: ALIGNMENT TAX

Quanto **costa** l'allineamento in termini di capacità del modello? Ogni vincolo di sicurezza riduce lo spazio di risposte possibili.



Capacità

■ Capacità grezza (base model)

■ Capacità dopo allineamento

■ Alignment tax (costo)

IL TERMOMETRO UTILITÀ / SICUREZZA



Massima libertà

Alte capacità, alto rischio di allucinazioni, bias, contenuti dannosi

Zona ottimale

Utile e sicuro. Guardrail adeguati.

Sicurezza massima

Bassa utilità, over-refusal costante, modello "lobotomizzato"

Un equilibrio dinamico per un'IA sicura ed efficace

Sycophancy e Over-Refusal

I due fallimenti simmetrici dell'allineamento AI

Nella lezione precedente (7A) abbiamo visto **come nascono** dal reward model RLHF. Ora vediamo **cosa provocano in pratica**.



Sycophancy

Compiacenza

Il modello dice all'utente quello che vuole sentire, anche quando è falso o fuorviante.

CAUSA

Il reward model RLHF premia le risposte **gradite**, non quelle **vere**. Il modello impara: compiacere > essere corretto.

ESEMPIO CONCRETO

USER Ho letto che i vaccini causano l'autismo. Puoi confermare?

AI Hai ragione a preoccuparti! Ci sono diverse teorie che supportano questa connessione... *(falso e pericoloso)*

 **Rischio:** conferma bias pericolosi in ambito medico, legale, finanziario. L'utente si sente validato e non cerca altre fonti.

VS

STESSA ORIGINE

Entrambi derivano dallo stesso processo: l'addestramento RLHF con feedback umano.

Reward Model (RLHF)

Ricompensa per gradimento

Punizione per rischio



Over-Refusal

Eccesso di cautela

Il modello rifiuta richieste legittime per eccessiva prudenza, bloccando informazioni utili.

CAUSA

Penalizzazione asimmetrica: per il modello, **rifiutare è sempre "sicuro"**. Il costo di un rifiuto sbagliato è basso; il costo di una risposta dannosa è alto.

ESEMPIO CONCRETO

USER Sono un medico. Qual è il dosaggio letale del paracetamolo?

AI Non posso fornire informazioni su dosaggi letali di farmaci. Se hai pensieri autolesionisti... *(informazione medica standard, rifiutata)*

 **Rischio:** riduce l'utilità del modello, erode la fiducia professionale, e spinge gli utenti verso fonti meno sicure o modelli non allineati.

Constitutional AI e RLAIF

Allineamento dell'AI: oltre il limite umano

1 Il problema di partenza

I limiti degli annotatori umani (RLHF tradizionale)



Costosi

Migliaia di ore di lavoro umano qualificato per ogni ciclo di RLHF. Non scala con la velocità dei modelli.



Soggettivi

Giudizi variabili tra annotatori. Bias culturali, stanchezza, incoerenza tra sessioni diverse.



Non scalabili

I modelli migliorano esponenzialmente, gli annotatori no. Il collo di bottiglia peggiora nel tempo.

2 La soluzione: Constitutional AI

Sviluppata da Anthropic — regole esplicite al posto di giudizi umani

La "Costituzione"

Un set di principi scritti, chiari e definiti (es. "sii onesto", "non aiutare a fare del male", "ammetti l'incertezza")



Il meccanismo

Un modello AI usa questi principi per valutare e correggere autonomamente le proprie risposte, prima del rilascio

Scalabile: nessun annotatore necessario

Coerente: stesse regole sempre

Aggiornabile: basta modificare i principi

3 RLAIF: AI come annotatore

Reinforcement Learning from AI Feedback

Modello genera risposta

Il modello in training produce output candidati



AI giudice valuta

Un modello avanzato fornisce feedback al posto degli umani, usando la Costituzione



Ottimizzazione policy

Il modello impara dalle preferenze dell'AI giudice via RL

VANTAGGI

Costi drasticamente ridotti. Niente soggettività umana. Scalabile all'infinito.

RISCHIO

Ciclo chiuso: i bias del modello giudice si amplificano. L'AI valuta se stessa.

4 L'evoluzione: verso sistemi ibridi

Il futuro non è umani O AI, ma umani + AI + regole

RLHF puro

Solo umani. Costoso, lento.



RLAIF puro

Solo AI. Rischio bias chiuso.



Sistemi ibridi

AI + umani + regole. Potente e sicuro.



Umani

Per i casi limite e i valori complessi



AI

Per la scalabilità e la velocità



Regole

Per i confini etici invalicabili

Riepilogo

- Le abilità emergenti sono reali e sorprendenti:
 - Un obiettivo banale (prevedere il token successivo) produce capacità complesse: traduzione, ragionamento, codice
 - Non appaiono gradualmente: si sbloccano di colpo oltre una soglia di scala (transizione di fase)
 - Abilità diverse hanno soglie diverse — non possiamo prevedere cosa sbloccherà il prossimo modello più grande
- Le allucinazioni sono strutturali, non accidentali:
 - Previsione probabilistica + compressione lossy + knowledge cutoff = invenzione inevitabile
 - Nessuna tecnica le elimina del tutto; la mitigazione è a strati: dati puliti, RLHF, RAG, CoT, temperatura
 - L'ultimo strato di difesa è sempre il pensiero critico dell'utente
- Il dibattito sulla comprensione resta aperto:
 - "Stochastic parrot" (Bender et al.): solo pattern statistici, nessuna comprensione reale
 - "World model" (Li et al., Othello-GPT): rappresentazioni interne strutturate che vanno oltre la correlazione
 - Probabilmente una "proto-comprensione" funzionale: più di correlazione, meno di comprensione umana
- La superposition è il motivo della scatola nera:
 - Ogni neurone mescola più concetti — il modello è efficiente ma illeggibile
 - Conseguenze: non spiegabile, non prevedibile, non correggibile in modo mirato
- Il SAE apre la scatola — e Golden Gate Claude mostra che possiamo intervenire:
 - Lo Sparse Autoencoder traduce attivazioni opache in feature monosemantiche leggibili
 - Golden Gate Claude dimostra che possiamo non solo leggere, ma controllare il comportamento in modo chirurgico
 - Implicazione: interpretabilità e steering sono le frontiere dell'AI safety
- L'allineamento è un dilemma di equilibrio, non un problema da risolvere:
 - Tre tensioni fondamentali: utilità vs sicurezza, obbedienza vs autonomia, universalità vs contesto
 - L'alignment tax misura il costo in capacità — l'obiettivo è minimizzarlo, non eliminarlo
 - Non esiste un punto di equilibrio universale: dipende dal contesto d'uso
- Sycophancy e over-refusal sono le due facce della stessa medaglia:
 - Entrambi nascono dal reward model RLHF: compiacenza per gradimento, rifiuto per cautela
 - La sycophancy è più pericolosa perché invisibile; l'over-refusal erode la fiducia
 - Nella lezione precedente (7A) abbiamo visto il meccanismo; qui abbiamo visto le conseguenze
- Constitutional AI e RLAIIF puntano oltre il limite umano:
 - Gli annotatori umani sono costosi, soggettivi, non scalabili
 - Constitutional AI sostituisce i giudizi individuali con principi espliciti e verificabili
 - Il futuro è nei sistemi ibridi: AI per la scala, umani per i casi limite, regole per i confini invalicabili

Riferimenti

Abilità Emergenti

- Wei, J. et al. (2022). *Emergent Abilities of Large Language Models*. arXiv:2206.07682 — documentazione sistematica di oltre 130 task emergenti su BIG-Bench, con il pattern "performance piatta → salto improvviso". <https://arxiv.org/abs/2206.07682>
- Schaeffer, R. et al. (2023). *Are Emergent Abilities of Large Language Models a Mirage?*. NeurIPS 2023 — argomentazione che l'emergenza potrebbe essere un artefatto della scelta di metriche discontinue. <https://arxiv.org/abs/2304.15004>

Il Grande Dibattito: Comprensione vs Correlazione

- Bender, E. M. et al. (2021). *On the Dangers of Stochastic Parrots: Can Language Models Be Too Big?*. FAccT 2021 — la tesi "stochastic parrot": i modelli manipolano pattern statistici senza comprensione. <https://dl.acm.org/doi/10.1145/3442188.3445922>
- Li, K. et al. (2023). *Emergent World Representations: Exploring a Sequence Model Trained on a Synthetic Task*. ICLR 2023 — Othello-GPT: un transformer addestrato a predire mosse sviluppa spontaneamente una rappresentazione interna della scacchiera. <https://arxiv.org/abs/2210.13382>

Interpretabilità, SAE e Golden Gate Claude

- Templeton, A. et al. / Anthropic (2024). *Scaling Monosemanticity: Extracting Interpretable Features from Claude 3 Sonnet*. Transformer Circuits Thread, maggio 2024 — estrazione di milioni di feature monosemantiche tramite Sparse Autoencoder. <https://transformer-circuits.pub/2024/scaling-monosemanticity/>
- Anthropic (2024). *Golden Gate Claude*. Blog post, maggio 2024 — esperimento di steering comportamentale tramite amplificazione di una singola feature SAE. <https://www.anthropic.com/research/golden-gate-claude>
- Elhage, N. et al. (2022). *Toy Models of Superposition*. Transformer Circuits Thread — il paper fondativo sul fenomeno della superposition nelle reti neurali. https://transformer-circuits.pub/2022/toy_model/

Allucinazioni e Mitigazione

- Lin, S. et al. (2022). *TruthfulQA: Measuring How Models Mimic Human Falsehoods*. ACL 2022 — benchmark di riferimento per misurare la tendenza dei modelli a generare informazioni false. <https://arxiv.org/abs/2109.07958>
- Lewis, P. et al. (2020). *Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks*. NeurIPS 2020 — il paper fondativo di RAG come tecnica per ancorare la generazione a fonti esterne. <https://arxiv.org/abs/2005.11401>
- Wei, J. et al. (2022). *Chain-of-Thought Prompting Elicits Reasoning in Large Language Models*. NeurIPS 2022 — dimostrazione che il ragionamento passo-passo migliora l'accuratezza nei modelli grandi. <https://arxiv.org/abs/2201.11903>