

Valutazione degli LLM



by Daniele Mantovani



I 4 Approcci alla Valutazione degli LLM

Come si misura se un modello "funziona"?

Ogni approccio cattura una dimensione diversa. Nessuno, da solo, racconta tutta la storia.

1



Benchmark Automatici

Test standardizzati su dataset fissi con risposta verificabile

- + Riproducibili, confrontabili, economici
- + Coprono capacità specifiche (coding, math, ragionamento)
- Soggetti a contaminazione e saturazione
- Gap tra punteggio e uso reale

Es. MMLU, HumanEval, GPQA, SWE-bench, ARC-AGI

2



Arena e Valutazione Umana

Confronti ciechi tra modelli, votati da utenti reali

- + Cattura preferenze reali su task aperti
- + Sistema Elo: classifica dinamica e robusta
- Costoso e lento da scalare
- Bias verso risposte "piacevoli" vs. corrette

Es. Chatbot Arena (LMSYS / LMArena)

3



LLM-as-a-Judge

Un modello forte valuta gli output di altri modelli

- + Scalabile e molto meno costoso degli umani
- + Buona correlazione con giudizi umani
- Bias: preferenza per risposte verbose
- Auto-preferenza del modello giudice

Es. GPT-4 / Claude come giudice, AlpacaEval

4



Metriche Tecniche

Performance pratiche: velocità, costo, contesto, sicurezza

- + Misurabili oggettivamente
- + Decisive per la scelta in produzione
- Non misurano l'"intelligenza" del modello
- Variano con infrastruttura e configurazione

Es. TTFT, TPS, \$/Mtok, context window, refusal rate

Messaggio chiave: La valutazione di un LLM è multidimensionale. Ogni approccio risponde a una domanda diversa — servono tutti.

Benchmark Automatici — La Mappa delle Capacità

Ogni benchmark misura una dimensione specifica. La tendenza: test sempre più difficili, dinamici e resistenti alla contaminazione.

Ragionamento Scientifico

GPQA Diamond DIFFICILE

Domande PhD in fisica, chimica, biologia. Gli esperti umani arrivano al 65–74%.

HLE NUOVO

2500 domande al confine della conoscenza umana, 100+ discipline. Nessun modello supera il 45%.

Matematica

AIME 2025 SATURATO

Competizione matematica pre-olimpiadi. Tutti i modelli frontier lo risolvono al 100%.

FrontierMath NUOVO

Problemi di ricerca matematica aperta. Il successore naturale di AIME.

Coding

SWE-bench Verified

Fix di bug reali da repository GitHub in produzione. Il gold standard per il coding.

Terminal-Bench 2.0 NUOVO

Task di coding agentico in ambiente terminale reale.

Ragionamento Astratto

ARC-AGI-2 DIFFICILE

Pattern logici visivi mai visti in training. Test di "vera" generalizzazione.

MMLU-Pro QUASI SATURATO

Conoscenza multidisciplinare a 10 opzioni, 57 domini. Versione più dura di MMLU.

Knowledge Work

GDPval-AA NUOVO

Task professionali reali (finanza, legale, ricerca). Misurato in Elo, alta rilevanza pratica.

BrowseComp NUOVO

Ricerca agentica multi-step su web di informazioni difficili da trovare.

Capacità Agentiche

OSWorld / WebArena NUOVO

Uso autonomo di computer e browser. Il nuovo terreno di scontro tra modelli.

TruthfulQA / SimpleQA

Misura la tendenza alle allucinazioni e alla generazione di fatti inventati.



Tendenza

I benchmark si saturano rapidamente. La frontiera si sposta verso test più difficili (HLE, ARC-AGI-2, FrontierMath) e task agentici reali.

La % indica la frazione di task risolti correttamente sul totale. Per i test a scelta multipla = risposte esatte; per i benchmark agentici = task completati. Eccezione: GDPval-AA usa un punteggio Elo.

Confronto Benchmark — Modelli Frontier (Feb. 2026)

Punteggi sui principali benchmark. Lo sfondo colorato indica il miglior risultato per riga.

Benchmark	● Claude Opus 4.6	● GPT-5.2	● Gemini 2.5 Pro	● DeepSeek V3.2	● Kimi K2.5
GPQA Diamond Scienze livello PhD	91.3%	93.2%	~85%	79.9%	87.6%
HLE Confine conoscenza umana	40.0%	~35%	44.4%	—	—
AIME 2025 Matematica competitiva	100%	100%	92%	89.3%	96.1%
SWE-bench Verified Software engineering reale	80.8%	80.0%	63.8%	77.8%	~70%
Terminal-Bench 2.0 Coding agentico	65.4%	64.7%	68.5%	—	—
ARC-AGI-2 Generalizzazione astratta	68.8%	52.9%	77.1%	—	—
MMLU-Pro Conoscenza multidisciplinare	~91%	~90%	~88%	~85%	92.0%
BrowseComp Ricerca web agentica	77.0%	65.8%	85.9%	—	—

Messaggio chiave: Nessun modello domina ovunque. La scelta dipende dal caso d'uso: coding, ragionamento, ricerca, costo.

■

 = miglior risultato per riga ~ = stima da fonti multiple corsivo su AIME = benchmark saturato (tutti al 100%) Dati: Anthropic, OpenAI, Google DeepMind model card, feb. 2026

Chatbot Arena — La Valutazione Umana degli LLM

Confronti ciechi tra modelli votati da utenti reali. Il sistema di valutazione considerato più affidabile.

COME FUNZIONA

- 1 L'utente pone una domanda**
Qualsiasi prompt: domanda, task creativo, codice, ragionamento. Task reali, non predefiniti.
- 2 Due modelli anonimi rispondono**
L'utente vede "Modello A" e "Modello B" — non sa quali siano. Confronto cieco (blind).
- 3 L'utente vota il migliore**
Scelta tra: A vince, B vince, pareggio. Solo dopo il voto vengono rivelati i nomi dei modelli.
- 4 Il sistema Elo si aggiorna**
Ogni voto aggiorna il punteggio Elo dei due modelli coinvolti. Migliaia di voti stabilizzano il ranking.

★ Il sistema Elo

Stesso principio degli scacchi: ogni modello ha un rating numerico. Vincere contro un modello forte fa guadagnare più punti che vincere contro uno debole.

Rating alto = il modello vince spesso nei confronti ciechi con utenti reali

Perché è considerata la valutazione più affidabile?

- + **Task reali e aperti** — gli utenti chiedono ciò che gli serve davvero, non domande predefinite
- + **Confronto cieco** — elimina il bias di brand ("preferisco GPT perché è GPT")
- + **Volume** — oltre 2 milioni di voti raccolti, risultati statisticamente robusti
- **Bias di stile** — gli utenti possono preferire risposte verbose o "piacevoli" a quelle corrette
- **Copertura limitata** — sovra-rappresenta conversazione generale, sotto-rappresenta coding e task tecnici

+ Collegamento con RLHF

La Chatbot Arena usa lo **stesso principio** dell'RLHF: preferenze umane pairwise ("A è meglio di B"). La differenza: l'RLHF le usa per **addestrare**, l'Arena per **valutare**.


Classifica Elo (estratto, feb. 2026)

1	Kimi K2.5		1447
2	GPT-5.2		~1440
3	Claude Opus 4.6		~1430
4	DeepSeek V3.2		~1421
5	Gemini 2.5 Pro		~1410

LLM-as-a-Judge — Valutazione Scalabile con AI

Un modello forte valuta gli output di altri modelli. Scalabile, ma con bias noti.

IL MECCANISMO



Vantaggi

- + **Scalabile:** migliaia di valutazioni in minuti, non settimane
- + **Correlazione umana:** ~80% di accordo con giudizi umani su task generali
- + **Costo:** 10-100x meno costoso della valutazione umana
- + **Riproducibile:** stesso prompt, stesso giudice = stesso risultato

Bias e limiti

- **Verbosity bias:** preferisce risposte lunghe e articolate, anche se non migliori
- **Auto-preferenza:** un modello giudice tende a preferire i propri output
- **Position bias:** tende a favorire il primo o l'ultimo output presentato
- **Cieco ai propri limiti:** non rileva errori che nemmeno lui saprebbe individuare

Quando ha senso usarlo?

- ✓ Valutare risposte su **task aperti** (riassunti, traduzioni, Q&A)
- ✓ **Screening rapido** di molte varianti prima della review umana
- ✓ Pipeline di **valutazione continua** in produzione (monitoring)
- ✗ **Non usarlo** come unica fonte per decisioni critiche di sicurezza

Varianti comuni

- **Pairwise:** confronta due output e sceglie il migliore (come l'Arena)
- **Reference-based:** confronta l'output con una risposta di riferimento
- **Single-point:** assegna un punteggio (1-5) a un singolo output
- **Multi-criteria:** valuta su più dimensioni (correttezza, stile, completezza)

Esempio pratico: AlpacaEval usa GPT-4 come giudice per classificare modelli su 805 istruzioni — correla ~85% con Chatbot Arena a una frazione del costo.

I Problemi della Valutazione degli LLM

Perché i benchmark non sono la verità -- e perché serve pensiero critico nel leggerli.



Contaminazione dei dati

Data Contamination

1

Le domande del benchmark finiscono nei dati di training. Il modello le ha "già viste" -- non sta ragionando, sta ricordando.

Esempio: se MMLU è nel dataset di pre-training, il modello "ricorda" le risposte invece di derivarle. I punteggi risultano gonfiati e non riflettono la reale capacità.

⚠ Punteggi artificialmente alti che non predicono la performance su domande nuove.



Saturazione

Benchmark Ceiling

2

I modelli frontier raggiungono punteggi vicini al 100%. Il benchmark non discrimina più tra modelli -- ha perso potere informativo.

Esempio: AIME 2025 risolto al 100% da Claude, GPT-5.2 e altri. MMLU-Pro sopra il 90% per tutti i top model. Servono benchmark sempre più difficili, in una rincorsa continua.

⚠ Necessità continua di nuovi benchmark -- ciclo di vita sempre più breve.



Overfitting sui benchmark

Teaching to the Test

3

I modelli vengono ottimizzati specificamente per eccellere nei benchmark, senza miglioramento reale delle capacità sottostanti.

Esempio: un modello addestrato con dati simili al formato MMLU ottiene punteggi altissimi su MMLU ma fallisce su domande formulate diversamente sullo stesso argomento. Come uno studente che memorizza le risposte dell'esame dell'anno scorso.

⚠ Miglioramento apparente senza vera generalizzazione.



Gap benchmark-pratica

Benchmark vs. Real World

4

Un modello eccelle nei test ma delude nell'uso reale. I benchmark misurano capacità isolate; il mondo reale richiede integrazione, contesto e robustezza.

Esempio: un modello con 95% su HumanEval (generazione codice isolata) può fallire nel debugging di un progetto reale con dipendenze, documentazione incompleta e requisiti ambigui (SWE-bench).


⚠ I benchmark non sostituiscono la valutazione sul proprio caso d'uso specifico.

Il punto critico: i benchmark sono utili come screening iniziale, ma non sono la verità. La valutazione finale deve essere fatta sul task reale, con dati reali, nel contesto reale.

Metriche Tecniche — Oltre l'"Intelligenza"

Le metriche non di capacità ma di performance pratica. In produzione, contano almeno quanto i benchmark.

PRESTAZIONI DI GENERAZIONE (LATENZA)



Capacità e contesto

- Context Window** Lunghezza massima input+output in token (128K-1M+)
- Needle in a Haystack** Capacità di recuperare info sepolte in contesti lunghi

Efficienza e costi

- \$/M token (in/out)** Costo economico per milione di token -- forbice 200x tra modelli
- Parametri / Quant.** Dimensione modello e tolleranza alla quantizzazione (INT8, INT4)

Sicurezza e allineamento

- Hallucination rate** Frequenza di informazioni fabbricate (misurata con TruthfulQA, SimpleQA)
- Refusal rate** Tasso di rifiuto su richieste legittime vs. dannose
- Bias (BBQ, WinoBias)** Misure di equità, pregiudizi di genere/etnia nelle risposte

In produzione: un modello che risponde in 3 secondi con 95% di accuratezza batte spesso un modello con 98% di accuratezza ma 15 secondi di latenza. La scelta è un trade-off multidimensionale.


Context Rot

Le prestazioni degradano all'aumentare dei token nella finestra di contesto -- la context window dichiarata non è quella effettiva

Il fenomeno: "Lost in the Middle"

I modelli recuperano bene le informazioni all'**inizio** e alla **fine** del contesto, ma le prestazioni calano per quelle nel **mezzo**. Il pattern è una curva a U: alta accuratezza ai bordi, un "buco" al centro. Più lungo è il contesto, più profondo è il buco.

Accuratezza nel recupero di un fatto per posizione nel contesto



Valori indicativi ispirati a Liu et al. (2024) "Lost in the Middle". I numeri variano per modello e task.

Perché succede

- **Distribuzione del training:** l'informazione rilevante tende a essere vicina al punto di predizione, non sepolta a metà di 100K token
- **Decadimento dell'attenzione:** i pesi si diluiscono su troppe posizioni -- il segnale si perde nel rumore
- **Posizionale, non semantico:** il degrado dipende da *dove* si trova l'info, non da *quanto* sia rilevante

Implicazione pratica

Un modello con context window da **200K token** non significa che recupera bene informazioni a 200K. La **context window effettiva** è spesso molto inferiore. Benchmark come **Needle in a Haystack** e **RULER** misurano questo gap.

Strategie di mitigazione

RAG selettivo

Solo i chunk rilevanti nel contesto, non interi documenti

Posizionamento strategico

Info critiche all'inizio o alla fine del prompt

Riassunti progressivi

Comprimere i turni vecchi invece di inviarli per intero

Context curation

Rimuovere attivamente contenuti non necessari

La context window dichiarata non è la context window effettiva. Meno contesto ma meglio curato batte sempre più contesto con informazioni sparse. Il contesto è una risorsa scarsa -- va gestita, non solo riempita.

Riferimenti

Classifiche e confronti live:

- [Chatbot Arena / LMArena](#) — classifica Elo basata su preferenze umane, il riferimento per la valutazione umana
- [Artificial Analysis](#) — confronto in tempo reale di latenza, throughput e qualità tra provider
- [LM Council Benchmarks](#) — aggregatore di benchmark con confronti tra modelli
- [Price Per Token](#) — confronto prezzi API aggiornato in tempo reale

Benchmark specifici:

- [SWE-bench](#) — il benchmark di riferimento per il software engineering reale
- [ARC-AGI](#) — il test di generalizzazione astratta, con la competizione ARC Prize
- [GPQA](#) — domande graduate-level in scienze
- [HLE \(Humanity's Last Exam\)](#) — il benchmark più difficile esistente, 2500 domande ai confini della conoscenza
- [MMLU-Pro](#) — versione estesa di MMLU a 10 opzioni

Model card ufficiali:

- [Anthropic \(Claude\)](#) — documentazione e model card di Claude
- [OpenAI \(GPT\)](#) — documentazione e system card di GPT
- [Google DeepMind \(Gemini\)](#) — technical report di Gemini
- [DeepSeek](#) — paper e model card open-source

Paper di riferimento:

- Zheng et al., 2023 — *"Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena"* — il paper fondativo sulla valutazione umana e LLM-as-Judge
- Li et al., 2023 — *"AlpacaEval: An Automatic Evaluator of Instruction-Following Models"* — il framework di valutazione automatica più usato
- Chollet, 2019 — *"On the Measure of Intelligence"* — il paper dietro ARC, sulla definizione di intelligenza e generalizzazione